

Ex013_Faculdade.R

junio


2025-08-02

```
# 1 )

# a) Criar o data frame e plotar o gráfico
dias <- c(1, 45, 90, 135, 180)
vitamina_c <- c(4.09, 3.27, 2.45, 3.27, 1.64)

dados <- data.frame(dias, vitamina_c)

# Plotando os dados
plot(dados$dias, dados$vitamina_c,
     main = "Teor de Vitamina C vs Dias de Armazenamento",
     xlab = "Dias de Armazenamento",
     ylab = "Vitamina C (mg/100ml)",
     pch = 19, col = "blue")
```



```
# b) Ajustar o modelo de regressão linear
modelo <- lm(vitamina_c ~ dias, data = dados)
summary(modelo) # Mostra os coeficientes da reta
```

```
##
## Call:
## lm(formula = vitamina_c ~ dias, data = dados)
##
## Residuals:
##      1      2      3      4      5
## 0.1711 -0.1680 -0.4962  0.8156 -0.3226
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.929797   0.465316   8.445  0.00348 **
## dias        -0.010929   0.004221  -2.589  0.08115 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5981 on 3 degrees of freedom
## Multiple R-squared:  0.6908, Adjusted R-squared:  0.5877
## F-statistic: 6.703 on 1 and 3 DF, p-value: 0.08115
```

```
# c) Prever o teor de vitamina C com 20 dias
predict(modelo, data.frame(dias = 20)) # Resultado previsto
```

```
##      1
## 3.711217
```


```
# d) Plotar novamente com reta e resíduos
plot(dados$dias, dados$vitamina_c,
     main = "Vitamina C vs Dias com Regressão e Resíduos",
     xlab = "Dias", ylab = "Vitamina C (mg/100ml)",
     pch = 19, col = "blue")

# Adicionar reta de regressão
abline(modelo, col = "red", lwd = 2)

# Valores ajustados
valores_ajustados <- fitted(modelo)

# Adicionar os resíduos (segmentos entre ponto real e ponto na reta)
segments(dados$dias, dados$vitamina_c, dados$dias, valores_ajustados, col = "gray")
```

Vitamina C vs Dias com Regressão e Resíduos



e) Conclusão

`summary(modelo)`

```
##
## Call:
## lm(formula = vitamina_c ~ dias, data = dados)
##
## Residuals:
##      1      2      3      4      5
## 0.1711 -0.1680 -0.4962  0.8156 -0.3226
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.929797   0.465316   8.445  0.00348 **
## dias        -0.010929   0.004221  -2.589  0.08115 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5981 on 3 degrees of freedom
## Multiple R-squared:  0.6908, Adjusted R-squared:  0.5877
## F-statistic: 6.703 on 1 and 3 DF, p-value: 0.08115
```

Pode-se concluir que, embora haja uma tendência de perda de vitamina C com o
tempo, outros fatores (como erros experimentais ou condições de armazenamento)

```
# podem estar influenciando o resultado, especialmente no ponto dos 135 dias.
```

```
# 2 )
```

```
# Dados
```

```
x <- c(5.2, 5.1, 4.9, 4.6, 4.7, 4.8, 4.6, 4.9)
```


```
y <- c(13, 15, 18, 20, 19, 17, 21, 16)
```

```
# Criar data frame
```

```
dados <- data.frame(x, y)
```

```
# a) Gráfico de dispersão
```

```
plot(dados$x, dados$y,  
     main = "Horas de Treinamento vs Tempo de Trabalho",  
     xlab = "Horas de Treinamento",  
     ylab = "Tempo para concluir o trabalho",  
     pch = 19, col = "blue")
```



```
# b) Regressão linear
```

```
modelo <- lm(y ~ x, data = dados)
```

```
summary(modelo) # Mostra coeficientes e R²
```

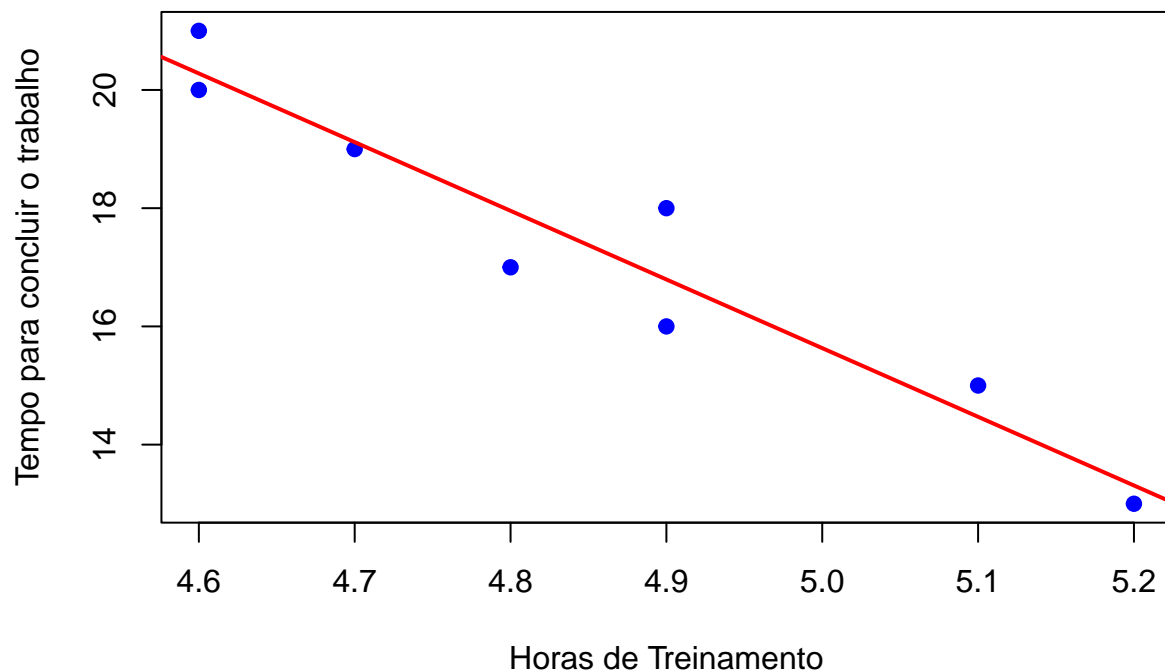
```
##
```

```
## Call:
```

```
## lm(formula = y ~ x, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.9559 -0.4301 -0.1985  0.5772  1.2059
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   73.721      6.785   10.865  3.6e-05 ***
## x            -11.618      1.398   -8.312 0.000164 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.815 on 6 degrees of freedom
## Multiple R-squared:  0.9201, Adjusted R-squared:  0.9068
## F-statistic: 69.09 on 1 and 6 DF,  p-value: 0.0001645
```

```
# c) Adicionar a reta de regressão ao gráfico
plot(dados$x, dados$y,
     main = "Regressão Linear - Horas de Treinamento vs Tempo de Trabalho",
     xlab = "Horas de Treinamento",
     ylab = "Tempo para concluir o trabalho",
     pch = 19, col = "blue")
abline(modelo, col = "red", lwd = 2)
```

Regressão Linear – Horas de Treinamento vs Tempo de Trabalho



```
# d) Coeficiente de determinação ( $R^2$ )
r2 <- summary(modelo)$r.squared
cat("Coeficiente de determinação  $R^2$  =", round(r2, 4), "\n")
```

```
## Coeficiente de determinação  $R^2$  = 0.9201
```

```
# Interpretar a equação da reta
a <- coef(modelo)[1]
b <- coef(modelo)[2]
cat("Equação da reta: y =", round(a, 4), "+", round(b, 4), "* x\n")
```

```
## Equação da reta: y = 73.7206 + -11.6176 * x
```

```
# cerca de 89% da variação no tempo de trabalho é explicada pelo tempo de treinamento.
# Como a inclinação é negativa, indica que quanto mais horas de treinamento,
# menor o tempo necessário para concluir o trabalho.
```